附件 1

2025 年河北省研究生创新资助项目结题报告书

项目负责人：　李赛

项目组成员：/

研究生类别：　博士研究生☑　　硕士研究生□

项 目 名 称：　基于深度学习模型的交通风吹雪灾害动态预测与评估研究

所 在 院 校：　石家庄铁道大学

所 在 学 院：　土木工程学院

专 业 名 称：　土木工程

河北省人民政府学位委员会办公室制

<table>
<tr><td>项目名称</td><td colspan="6">基于深度学习模型的交通风吹雪灾害动态预测与评估研究</td></tr>
<tr><td>项目编号</td><td colspan="2">CXZZBS2025166</td><td>计划完成时间</td><td>2026 年 3 月</td><td>实际完成时间</td><td>2026 年 2 月</td></tr>
<tr><td rowspan="2">项目负责人</td><td>姓　名</td><td>李赛</td><td>年级</td><td>2023 级</td><td>指导教师</td><td>马文勇</td></tr>
<tr><td>主要工作</td><td colspan="5">研究方案执行，现场实测执行，测试数据分析、整理</td></tr>
<tr><td rowspan="2">项目主要参加人</td><td>姓　名</td><td>年级</td><td colspan="2">学科专业</td><td colspan="2">主 要 贡 献</td></tr>
<tr><td>/</td><td>/</td><td colspan="2">/</td><td colspan="2">/</td></tr>
<tr><td colspan="7">项 目 实 施 情 况 报 告</td></tr>
<tr><td colspan="7">（包括项目计划要点，执行情况概述。是否按计划进行，哪些内容作了必要的调整和变动，哪些研究内容未按计划进行等方面，不超过 1500 字）

项目立项时，计划以多源气象数据为基础，构建交通风吹雪灾害预测模型，重点包括：1）开展风吹雪监测数据与气象数据的整理、清洗和标准化处理；2）基于气象数据尝试建立风吹雪易发性预测模型；3）基于多变量时间序列预测模型，用于现场气象信息预测；4）结合 ERA5 等再分析资料，服务于交通线路风吹雪灾害的长期评估和局部路段预警应用。
项目执行过程中，围绕原定研究目标持续推进，整体上完成了风吹雪灾害机理认识、数据驱动预测方法构建、典型路段灾害模拟分析等核心工作，并取得了较为系统的阶段性成果。首先，在风吹雪发生条件研究方面，依托川藏线高海拔山区道路现场调查与实测数据，对不同雪类条件下的起动风速开展了实证研究，识别了风吹雪主要发生时段、主要高风险海拔区间，并建立了分层级风吹雪易发性模型。
其次，在数据驱动预测方法方面，项目结合 ISAW 长期监测资料，完成了基于可解释机器学习的风吹雪事件检测研究。实际执行中，考虑到风吹雪事件样本特征、数据规模、可解释性需求以及模型泛化稳定性，项目在原计划深度学习框架基础上，进一步强化了可解释机器学习路线，建立了风吹雪检测模型。研究结果表明，该模型能够较好识别风吹雪事件。
此外，围绕交通线路典型场景应用，项目结合西藏东南部高海拔山区道路现场调研，开展了典型道路断面风吹雪数值模拟研究。通过现场勘察与 CFD 相结合的方法，分析了山坡坡度、边坡开挖角度等因素对积雪分布的影响，明确了不同坡度条件下流场分离、涡旋区迁移及坡脚积雪增强等规律，为复杂山区道路风吹雪风险识别和工程设计提供了定量支撑。
项目实施基本按计划推进，完成了数据整理、现场调查、机理分析、预测模型构建及典型场景模拟等主要研究内容，并取得了论文发表等成果。原计划中基于 ERA5 的大范围长期评估及基于 TFT 的局地实时预警研究，尚未作为本阶段最终成果完整产出，后续拟在已有研究基础上继续深化。总体而言，项目达到了预期的阶段性目标。</td></tr>
</table>

成果综述
（包括研究工作主要进展和所取得的成果，成果的基本内容、学术价值、社会效益、试用范围及效果等，不超过 2000 字） 项目围绕交通风吹雪灾害的发生条件识别、数据驱动预测建模及典型道路场景灾害机理分析开展研究，形成了较为系统的阶段性成果。项目实施期间，研究工作主要包含现场观测与规律总结、机器学习预测模型构建以及典型路段数值模拟分析，取得了多篇论文成果，较好支撑了项目预定目标的实现。 在风吹雪发生条件研究方面，项目依托青藏高原东南部高海拔山区道路现场观测，系统分析了不同雪类条件下风吹雪发生的差异特征，提出了多层级风吹雪易发性模型。研究表明，风吹雪事件主要发生于每年 12 月至次年 2 月，受影响道路主要分布在海拔 3000 m 以上山区。依据积雪物理特征，可将地表积雪划分为新降雪、轻度固结雪和经历冻融循环的压实雪三类，其对应的 10 m 高度平均起动风速分别为 9.65 m/s、14.77 m/s 和 23.15 m/s。该成果深化了对高海拔山区风吹雪形成条件的认识，为交通线路风吹雪易发性判识、预警阈值确定和模型参数选取提供了更具针对性的实测依据。 在风吹雪事件预测建模方面，项目基于欧洲阿尔卑斯地区 ISAW 长期监测资料，构建了可解释机器学习检测模型，实现了风吹雪事件识别与关键气象因子贡献分析。研究结果表明，该模型对非风吹雪事件的识别精度超过 0.94，对风吹雪事件的识别精度达到 0.77～0.80；最大风速、平均风速、气温和相对湿度是影响风吹雪发生的主要因素，其中气温低于-3 ℃时更有利于风吹雪发生。与传统经验公式或固定阈值方法相比，该成果的优势在于能够从多要素观测数据中直接建立预测关系，同时借助 SHAP 方法揭示各因子的相对贡献，提高了模型结果的可解释性和应用可信度。该研究对风吹雪事件智能识别、灾害风险快速判别和数据驱动气象灾害研究具有较高参考价值。 在颗粒输运类灾害的数据驱动识别方法方面，项目还进一步拓展研究思路，形成了高频输运事件可解释建模成果。相关研究基于高频风速和输运通量同步观测数据，系统比较了原始风速分量、一阶统计量、波动速度、摩擦速度及湍流强度等特征在事件检测中的表现。研究结果表明，基于滚动时间窗的一阶统计量能够获得优于传统阈值或概率方法的预测效果，近地层流向风速是最关键的判别因子，最优时间窗约为 30 s。研究为颗粒起动类灾害的高频监测、特征筛选和可解释预测提供了新的技术路径。

在典型道路场景灾害机理研究方面，项目结合西藏东南部高海拔山区道路现场调研，围绕典型道路断面的风吹雪分布特征开展了数值模拟研究。该研究采用现场勘察与计算流体力学相结合的方法，在 Eulerian–Eulerian 多相流模拟框架下，分析了山坡坡度和边坡开挖角度对流场结构及积雪分布的影响。研究表明，当坡度大于 15° 时，迎风坡顶部易发生流动分离并在背风侧形成涡旋区，雪粒主要在该区域沉积；随着坡度减小，涡旋区向坡脚迁移并最终消失。边坡开挖会引起坡脚附近流场畸变，使积雪向上风侧坡脚迁移并显著增高。该成果从工程场景出发揭示了复杂山区道路断面风吹雪分布的动力学机制，为高寒山区道路选线优化、断面设计和防雪工程布设提供了定量依据。

在学术层面，项目从现场实测、机器学习建模和数值模拟三个角度，丰富了交通风吹雪灾害研究的方法体系。在社会效益方面，相关成果已服务于高寒山区公路和铁路的防灾减灾、交通运行保障和应急预警，对提升高海拔地区交通安全水平具有积极意义。在试用范围上，成果适用于高寒积雪区交通线路风吹雪灾害识别与评估，尤其适合用于海拔较高、地形复杂、强风与积雪共同作用显著的山区道路场景；其中，经验模型和可解释机器学习成果可用于灾害风险初判与监测预警，典型断面模拟成果可用于工程设计与防治措施优化。

成 果 清 单

序号	成 果 名 称	成果形式	作者	时间
1	Feature contributions and predictive modeling of aeolian sand transport detection in the atmospheric surface layer	论文	Li, S., Ma, W., Ma, J., Zhang, Z., & Yang, K.	2026.02.10


土木工程学院
2025年研究生创新资助项目
结题报告
基于深度学习模型的交通风吹雪灾害
动态预测与评估研究
汇报人：李赛（土博2023）
指导教师：马文勇 教授
2026.04.17
土木工程学院

一、立项依据（包括项目来源，研究意义，国内外研究现状、水平和发展趋势，选题的独创性等，并附主要参考文献及出处）

项目来源

风吹雪是一种由强风和大量飘移的雪粒引发的自然灾害，在寒冷的高海拔山区尤为常见。当地面的表层雪粒受到风力的作用后，被吹入空中并在空中相互碰撞、粘结。风雪流的能量相对较低时，这些空中的雪粒沿着抛物线轨迹下降，最终重新降落在地面上，形成一个由起始、飘移和重新附着过程组成的循环。风吹雪能够重新分配积雪量，驱动产生非均匀积雪，所形成的积雪深度通常是自然雪深度的 3 到 8 倍[1]。

风吹雪现象会导致积雪过量堆积，对人类活动带来严重影响，甚至可能引发雪崩等次生灾害[2]。当风吹雪发生在道路上时，空中飘浮的雪颗粒会显著增加近地表处的雪浓度，造成驾驶者视程受阻，从而增加交通事故的风险[3]。此外风吹雪具有对积雪的重分配作用，会在路面形成二次积雪，进一步降低道路的通行能力，严重时甚至可能导致交通堵塞[4]。

在铁路交通中，风吹雪堆积在道岔和清除叉上的积雪会加剧高速列车通过时的振动，显著影响列车运行的平稳性和乘客的舒适度。在极端情况下，这种振动甚至可能引发列车脱轨事故[5]。此外，轨道上的积雪还会显著降低轮轨之间的粘着系数，导致制动系统失效，延长紧急制动距离，从而增加列车追尾的风险。这种情况将导致区域列车密度和高山铁路运力的下降，进一步影响铁路运输的安全性和效率[6]。



(a)视程障碍　　(b)二次积雪　　(c)列车脱轨

图 1 交通线路风吹雪灾害(a,b: S201,中国新疆; c:新干线,日本秋田)

中国的地表积雪资源极为丰富，而风吹雪现象主要集中在高纬度、高海拔以及地形起伏变化显著的稳定积雪区。调查显示，风雪流多发区包括青藏高原及其周边山区、天山西北部、阿勒泰地区、东北和内蒙古高原，总面积占全国国土面积的 55.2%[7]。我国的多个重要经济走廊，如中巴经济走廊、中蒙俄经济走廊等，大部分都经过这些风雪流多发区。近年来，多条穿越风吹雪多发地带的高速铁路相继投入运营，包括哈大高铁、兰新高铁和京张高铁等。**上述经济走廊的开通和高铁线路的运行，进一步凸显了研究交通风吹雪灾害形成机制的重要性。亟需准确量化风吹雪对交通基础设施的影响，从而保障高寒地区交通安全，提升运输效率。**

研究意义

风吹雪灾害对交通基础设施的威胁在高寒地区尤为严重，现有的预测模型往往依赖于现场风速这一动态参数，然而风速的测量往往受限于现场条件，难以精确捕捉风吹雪发生的瞬时性与复杂性，这些因素导致传统模型在实际应用中的准确性和适用性受到限制。因此利用基于时间序列预测的深度学习模型可以消除对现场风速的依赖，提升风吹雪灾害预测模型的准确性和适用性，从而进一步改进其在道路风雪灾害评估和预测方面的应用。

本研究拟通过引入深度学习算法，提出一种创新性的风吹雪灾害预测方法，能够有效解决传统模型在风速依赖性方面的局限性。具体而言，本研究将时间序列预测模型应用于风吹雪灾害判断中，通过 1D 卷积神经网络（1D-CNN）和长短期记忆网络（LSTM）的结合，实现对风速空间模式和时间特征的精准提取。这种方法不仅可以提升模型对风吹雪灾害的预测能力，还使得预测模型能够更好地适应不同的环境条件和积雪特性，增强了模型的鲁棒性。

此外，本研究拟利用 ERA5 气象数据进行大尺度、长期的风吹雪灾害评估，并结合现场实测风速与 Temporal Fusion Transformers（TFT）模型，进行具体路段的短期实时预测。通过将长期和短期两种时间尺度的预测方法相结合，能够相互补充，形成更加全面的评估体系。这一创新方案将为高寒地区交通线路的安全管理提供坚实的技术支持，有效提升风吹雪灾害的预警能力和应对效率。

国内外研究现状、水平和发展趋势

风吹雪的发生主要取决于多种环境气象条件（如风速和气温）、雪层特性（如硬度、密度和粒径）以及植被特性，其中风是山地地形中风雪流的主要驱动力之一[8]。在微观尺度中，当雪表面附近的风剪应力超过雪粒的抗力时，就会发生风吹雪现象。在更为宏观的风吹雪灾害评估模型中，风吹雪的发生通常被认为是当风速超过某一临界值时开始的，即“起动风速”（Threshold wind speed）。确定这一参数对现有的大多数风吹雪预测模型至关重要，因为这些模型中的吹雪输送模块只有在风速超过起动风速时才会被激活[9]。因此，准确估计起动风速，对于预测风吹雪的发生以及量化其后续影响至关重要。尽管关于以起动风速为基础的风吹雪预测研究，目前各国学者已经开展了大量工作，但不同研究对阈值风速的估计仍存在显著差异。

早期研究大多假设一个恒定的起动风速，如 Mellor 的研究指出，对于松散和未板结的积雪，10 米高度下的起动风速通常在 3 到 8m/s 之间，而对于克服由冻融循环形成的雪层粘结力，风速可能需要达到 30 m/s[10]。Berg 和 Schmidt 在科罗拉多州 Niwot Ridge 进行的研究发现，1m 高度处的风速为 4 到 6 m/s 时（10 米高度处约 5.7 到 8.6 m/s，粗糙度高度为 0.005m）即可引发积雪的输送[11][12]。Li 和 Pomeroy 在加拿大草原地区进行的一项研究显示，湿雪运输的时均阈值风速大多在 7 到 14 m/s 之间（平均为 9.9 m/s），而干雪运输的阈值风速则在 4 到 11 m/s 之间（平均为 7.7 m/s）[13]。Liston 等人的研究指出，对于新形成或略微老化的冷干雪，10 米高度处的典型阈值风速范围为 4 到 5 m/s[14]。

尽管早期研究承认不同雪类型之间的差异（如水分含量或沉积时间），但大多仍采用恒定的阈值风速来预测风吹雪的发生。这种方法虽然简单，但由于忽略了风吹雪发生的物理特性在不同测量条件下的时空变异性，这一假设的局限性逐渐显现出来。Baggaley 和 Hanesiak 的研究指出，不同研究中阈值风速的差异主要归因于风速、空气温度以及积雪特性的差异[15]。因此，在不同观测区域之外应用恒定的阈值风速来检测雪粒的启动，可能会受到这些因素的显著影响[16]。

随着对风吹雪研究的深入，越来越多的研究表明起动风速不是一个固定不变的量，而是受环境条件和积雪特性影响的动态参数。Schmidt 指出了环境气温、湿度、雪粒粒径、冲击力和沉积时间对阈值风速的影响，并推导出了一种明确描述雪粒粘结阻力的公式[17]。一些研究尝试将阈值风速与雪的变质过程[18]、雪层特性（如雪密度[19]）以及雪粒之间的粘结直径[20]联系起来。Li 和 Pomeroy 总结认为，雪的粘结、凝聚和摩擦特性主要受空气温度的影响，并基于加拿大草原 16 个气象站的标准地表气象观测数据，提出了一种用于预测雪运输起始的阈值风速经验公式[21]。此外，Li 和

Pomeroy 还提出了一种统计方法，通过假设雪粒运动概率分布近似于累积正态分布，来研究风吹雪的发生。这些实用的经验解决方案，结合风洞实验和现场实验结果，进一步表明阈值风速是一个动态参数，其准确估计需要综合考虑多种环境参数和积雪特性的影响[22][23]。

近年来，新的雪粒运动阈值条件预测方案不断涌现，其中机器学习（Machine Learning，ML）已经成为一个重要的研究方向。机器学习方法，特别是深度学习技术（Deep Learning，DL）为起动风速的预测提供了新的视角和方法。例如，时间序列预测可以利用历史风速、气温和降雪数据，结合先进的预测模型，来提高起动风速的预测准确性。

1D 卷积神经网络（1D-CNN）自 2015 年由 Kiranyaz 等人首次提出用于处理特定患者的心电图（ECG）信号以来，在信号处理领域得到了广泛应用，并展现出了先进的性能[24]。目前 1D-CNN 在包括结构健康监测、结构损伤检测、高功率引擎故障监测等方面均取得了显著成效[25]。1D-CNN 通过其强大的局部特征提取能力和池化层设计，能够有效捕捉数据中的空间模式[26]。这一特性使其在风吹雪起动风速的预测中展现出了巨大的潜力。1D-CNN 能够通过识别风速数据的空间模式，帮助确定阈值风速的变化趋势，从而提高风吹雪事件预测的准确性。

此外，长短期记忆网络（LSTM）作为一种处理时间序列数据的递归神经网络，也在气象灾害预测中得到了广泛应用。LSTM 最初由 Hochreiter 和 Schmidhuber 于 1997 年提出，通过添加多个门控机制，它在记忆和遗忘之间取得了良好的平衡，从而在处理时间序列预测问题时，通常能够获得最先进的结果[27]。与传统的递归神经网络（RNN）相比，LSTM 网络能够有效克服 RNN 中的梯度消失问题，这使得它在处理短期或长期数据建模时更加精确。在风吹雪起动风速的预测中，LSTM 能够更好地识别风速数据中的时间相关性，从而提高预测的准确性[28]。

在现场环境信息预测方面，Temporal Fusion Transformers（TFT）模型广泛应用于时间序列预测。TFT 是一种深度学习模型，由 Google Cloud AI 团队提出，其主要结构包括编码器和解码器。编码器部分将时间序列的历史数据作为输入，而解码器部分则以自回归的方式预测未来值。解码器通过注意力机制与编码器相连，使得解码器能够在进行预测之前，重点关注时间序列历史数据中对目标值预测最有价值的部分[29]。编码和解码的组合结构使得 Transformers 能够处理复杂的时间序列数据，具有强大的特征选择和关系建模能力，可以更好地捕捉数据中的长程依赖性和非线性特征，从而更准确地估计现场风速。

综上所述，风吹雪灾害评估与预测研究现状如图 2 所示，研究已经从早期采用恒定阈值风速的方法，逐步转向将其视为受环境条件和积雪特性显著影响的动态参数。

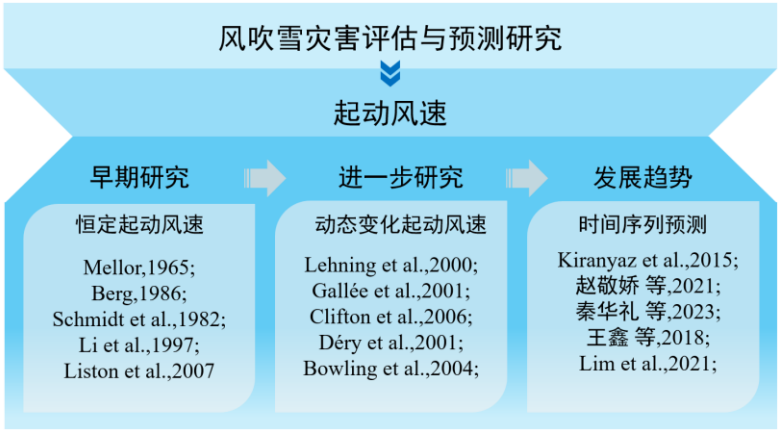


图 2 风吹雪灾害评估预测研究现状

然而由于传统研究方法难以准确量化复杂的环境变量和积雪特性，精确量化起动风速一直面临诸多挑战。随着机器学习（ML）和深度学习（DL）技术的引入，风吹雪灾害预测取得了显著进展。通过 1D-CNN 和 LSTM 等模型的应用，不仅可以有效捕捉风速数据中的空间模式和时间相关性，还显著提高交通风吹雪灾害预测的准确性和预测模型的鲁棒性。

选题的独创性

现有的研究在风吹雪灾害的预测方面已经取得了大量进展，但在其中的一些方面，仍然存在一定的局限。基于此，本研究的独创性体现在以下几个方面：

(1) **建立一种消除风速依赖性的风吹雪发生预测方案：**现有研究大多数依赖现场风速，将雪通量不为零时的现场风速作为起动风速。然而，在实际情况下，现场风速通常高于起动风速，并且这两者之间的差距并不明确，导致从现场测量中准确获取起动风速变得困难。因此，这种方法往往存在局限性。为解决这一问题，本研究计划开发一种基于时间序列预测模型的风吹雪发生判断方法。通过这一方法，研究将输入的环境条件直接用于预测风吹雪发生的概率，从而避免了直接计算起动风速的复杂性，消除了模型对现场风速的依赖。这种方法不仅简化了风吹雪预测过程，还提高了模型的适用性和准确性。

(2) **利用 1D-CNN 与 LSTM 融合模型优势进行综合预测：**本研究创新性地结合了 1D 卷积神经网络（1D-CNN）和长短期记忆网络（LSTM），以提升风吹雪灾害的预测准确性和模型鲁棒性。1D-CNN 擅长提取风速数据中的空间特征，从而捕捉局部模式；而 LSTM 则处理时间序列数据中的长期依赖关系，准确识别时间变化趋势。这种融合模型有效结合了空间特征和时间动态，弥补了传统方法中难以考虑时空特征的不足，为风吹雪灾害模型的建立增加更多特征。

(3) **基于现场环境信息实时预测（Real-time Forecast）的实现：**考虑到大尺度气象预测在具体交通线路路段上的局限性，本研究拟采用 Temporal Fusion Transformers（TFT）模型，进行实时风速、温度和降水等环境信息的预测。TFT 模型凭借其强大的特征选择和关系建模能力，能够准确捕捉现场环境信息的动态变化，提供更为精细的现场预测，并有效处理时间序列数据中的长程依赖性和非线性特征。该方法可为风吹雪灾害的实时判断和应对提供了实时数据支持，提高了对风吹雪灾害动态变化的响应能力。

参考文献

[1] Tabler R D. Design guidelines for the control of blowing and drifting snow[M]. Washington, DC: Strategic Highway Research Program, National Research Council, 1994.

[2] Schweizer J, Bruce Jamieson J, Schneebeli M. Snow avalanche formation[J]. Reviews of Geophysics, 2003, 41(4).

[3] 马磊,冉武平,李钰,等.基于博弈论组合赋权的平原公路风吹雪雪阻危险度评价研究[J].自然灾害学报,2022,31(03):85-92.

[4] 施佳誉,徐冬英,夏才初,等.公路风吹雪雪阻分布规律及雪灾形成机理研究[J].公路,2020,65(01):257-264.

[5] Zhu J Y, Hu Z W. Flow between the train underbody and trackbed around the bogie area and its impact on ballast flight[J]. Journal of Wind Engineering and Industrial Aerodynamics, 2017, 166: 20-28.

[6] Spiryagin M, Polach O, Cole C. Creep force modelling for rail traction vehicles based on the Fastsim algorithm[J]. Vehicle System Dynamics, 2013, 51(11): 1765-1783.

[7] 王中隆,张志忠.中国风吹雪区划[J]. 山地学报, 1999,(04):312-317.

[8] Reynolds D S, Pflug J M, Lundquist J D. Evaluating wind fields for use in basin‐scale distributed snow models[J]. Water Resources Research, 2021, 57(2): e2020WR028536.

[9] Xie Z, Ma Y, Ma W, et al. Comparison of varied complexity parameterizations in estimating blowing snow occurrences[J]. Journal of Hydrology, 2023, 619: 129291.

[10] Mellor M. Blowing Snow. Monogr. III-A3C[J]. US Army Cold Regions Research and Engineering Laboratory, 1965.

[11] Berg N H. Blowing snow at a Colorado alpine site: measurements and implications[J]. Arctic and Alpine Research, 1986, 18(2): 147-161.

[12] Schmidt R A. Vertical profiles of wind speed, snow concentration, and humidity in blowing snow[J]. Boundary-Layer Meteorology, 1982, 23(2): 223-246.

[13] Li L, Pomeroy J W. Probability of occurrence of blowing snow[J]. Journal of Geophysical Research: Atmospheres, 1997, 102(D18): 21955-21964.

[14] Liston G E, Haehnel R B, Sturm M, et al. Simulating complex snow distributions in windy environments using SnowTran-3D[J]. Journal of Glaciology, 2007, 53(181): 241-256.

[15] Baggaley D G, Hanesiak J M. An empirical blowing snow forecast technique for the Canadian arctic and the Prairie provinces[J]. Weather and forecasting, 2005, 20(1): 51-62.

[16] Xie Z, Ma W, Ma Y, et al. Decision tree-based detection of blowing snow events in the European Alps[J]. Hydrology and Earth System Sciences, 2021, 25(7): 3783-3804.

[17] Schmidt R A. Threshold wind-speeds and elastic impact in snow transport[J]. Journal of Glaciology, 1980, 26(94): 453-467.

[18] Lehning M, Doorschot J, Bartelt P. A snowdrift index based on SNOWPACK model calculations[J]. Annals of Glaciology, 2000, 31: 382-386.

[19] Gallée H, Guyomarc'h G, Brun E. Impact of snow drift on the Antarctic ice sheet surface mass balance: possible sensitivity to snow-surface properties[J]. Boundary-Layer Meteorology, 2001, 99: 1-19.

[20] Clifton A, Rüedi J D, Lehning M. Snow saltation threshold measurements in a drifting-snow wind tunnel[J]. Journal of Glaciology, 2006, 52(179): 585-596.

[21] Li L, Pomeroy J W. Estimates of threshold wind speeds for snow transport using meteorological data[J]. Journal of Applied Meteorology and Climatology, 1997, 36(3): 205-213.

[22] Déry S J, Yau M K. Simulation of an Arctic ground blizzard using a coupled blowing snow–atmosphere model[J]. Journal of Hydrometeorology, 2001, 2(6): 579-598.

[23] Bowling L C, Pomeroy J W, Lettenmaier D P. Parameterization of blowing-snow sublimation in a macroscale hydrology model[J]. Journal of Hydrometeorology, 2004, 5(5): 745-762.

[24] Kiranyaz S, Ince T, Hamila R, et al. Convolutional neural networks for patient-specific ECG classification[C]//2015 37th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC). IEEE, 2015: 2608-2611.

[25] 赵敬娇,赵志宏,杨绍普.基于残差连接和 1D-CNN 的滚动轴承故障诊断研究[J].振动与冲击,2021,40(10):1-6.

[26] 秦华礼,祝艺露.基于 RF-1D-CNN 的城市地下综合管廊施工安全风险评估[J].安全与环境学报,2023,23(07):2184-2190.

[27] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural computation, 1997, 9(8): 1735-1780.

[28] 王鑫,吴际,刘超,等.基于 LSTM 循环神经网络的故障时间序列预测[J].北京航空航天大学学

报,2018,44(04):772-784.
[29] Lim B, Arık S Ö, Loeff N, et al. Temporal fusion transformers for interpretable multi-horizon time series forecasting[J]. International Journal of Forecasting, 2021, 37(4): 1748-1764.

二、研究目标、研究内容和拟解决的关键问题

研究目标

(1) 构建风吹雪灾害预测模型：利用 ISAW 和 ECCC 的多要素气象数据，结合 1DCNN-LSTM 融合深度学习模型，开发能够在复杂气象条件下准确预测风吹雪灾害的模型。

(2) 提升交通线路沿线的风吹雪灾害评估能力：基于风吹雪灾害预测模型，结合 ERA5 长期气象数据，实现大范围的风吹雪灾害长时间评估，为风雪灾害路段交通线路设计提供支持。

(3) 加强现场气象信息预测的精准性：通过集成多种气象传感器和实时监测数据，改进 TFT 模型对现场气象变量（如风速、气温、湿度等）的预测精度，增强其在山区道路中的适用性。

(4) 应用模型实现灾害预警与应急管理：在实际道路沿线部署气象站，利用优化后的预测模型实现风吹雪灾害的实时预警，为风雪灾害路段现有交通线路的应急管理提供数据支持。

研究内容

(1) 数据收集与预处理：整合来自 ISAW 和加拿大 ECCC 的气象数据，其中包括风速、温度、湿度、降水量、积雪深度等关键气象参数。对数据进行清洗、标准化处理，并按时间顺序划分为训练集、验证集和测试集，确保数据的完整性和一致性。

(2) 1DCNN-LSTM 模型构建：基于深度学习方法，设计 1DCNN-LSTM 融合模型，以捕捉风吹雪事件的短期变化和长期演变趋势。1D CNN 层用于提取时间序列数据的局部特征，LSTM 层负责建模长期依赖关系。

(3) TFT 多变量时间序列模型构建：结合 Transformer 架构，利用 TFT 模型以处理复杂的多变量气象数据，实现对风速、温度、湿度等气象变量的精确预测。该模型将重点关注山区路段的风吹雪灾害预测，通过捕捉气象变量之间的交互关系，提升预测精度。

(4) 模型优化与测试：通过交叉验证和超参数调优，评估和优化模型性能，并通过不同气象变量组合测试模型的实际应用能力，确保模型具备高泛化能力和可靠性。

拟解决的关键问题

(1) 风吹雪灾害预测精度：山区复杂的地形条件对气象因素的影响巨大，如何复杂环境下提高风吹雪灾害的预测精度是本研究面临的主要挑战之一。1DCNN-LSTM 和 TFT 模型的构建与优化，通过结合短期和长期的时间序列特征，提升预测的准确性。

(2) 多变量时间序列数据处理：风吹雪灾害的发生与多种气象因素密切相关，如何有效处理这些复杂的多变量时间序列数据，并准确预测其相互作用下的结果，是本研究的另一关键问题。本研究通过引入 TFT 模型，完成对现场多要素气象信息的预测。

(3) 多尺度风吹雪灾害评估预测：风吹雪灾害具有多尺度特性，包括大范围区域尺度以及线路局部风致雪堆积（关键工况点）。准确预测不同尺度、时间跨度风吹雪灾害，并提出针对性的防治策略，是实现交通道路风吹雪灾害全面防治的最终目标。

三、课题的研究方法、技术路线、实验方案（含创新性）及其可行性分析

研究方法

（1）模型训练数据集

本研究的训练数据来自 ISAW (International Snow and Weather Station)，涵盖了雪通量及地表气象变量的观测数据。其中连续采集数据包括在 3.5mm 高度测量的平均风速（WS）和最大风速（WS-MAX）、风向（WD）、气温（T）、相对湿度（RH）、积雪深度（SD）以及降水量（TP）等参数，这些数据来自大约 30 个观测站点，其分布范围如图 3 所示，位于阿尔卑斯山脉与比利牛斯山脉的道路沿线。地表气象数据以每分钟为频率进行测量，并存储为每小时的平均值。

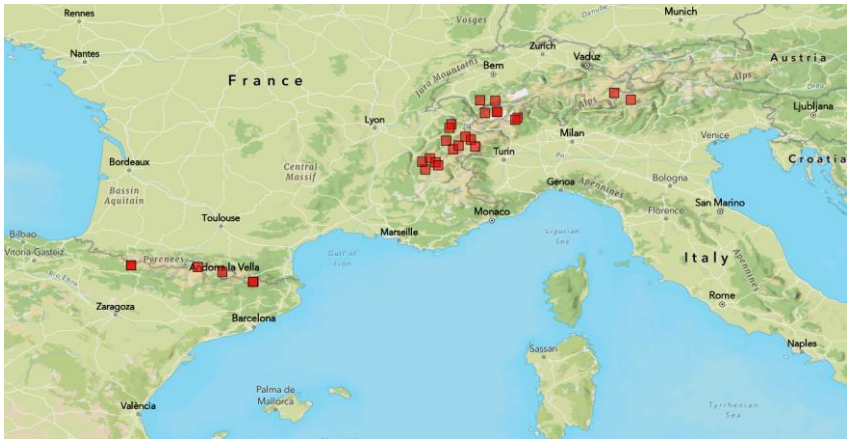


图 3 观测站点分布

虽然不同观测站点的可用气象变量有所不同（例如只有 Fmor、Fcmb、Fber、Fhue 和 Fgie 站点提供相对湿度数据），但每个 ISAW 站点都配备了 FlowCapt 声学传感器（图 4），在风吹雪监测中，FlowCapt 通过检测雪流撞击和风引起的层流空气摩擦所产生的内部声压变化，实现对于风吹雪的动态的捕捉。



图 4 FlowCapt 雪通量采集仪

在本研究中，计划选择 10 个包含上述观测数据的站点用于模型训练和测试，所选择的站点信息和数据时间范围如表 1 所示。其中由于各站点建立时间不同，所以数据开始采集时间不同。Fsal 站点用于敏感性测试，并最终构建时间序列预测模型。利用上述站点所采集的风吹雪和气象信息，

能够最大化使用不同维度的观测数据，从而构建一个高效的风吹雪起动风速预测模型，用于识别实际交通线路沿线的风吹雪事件。

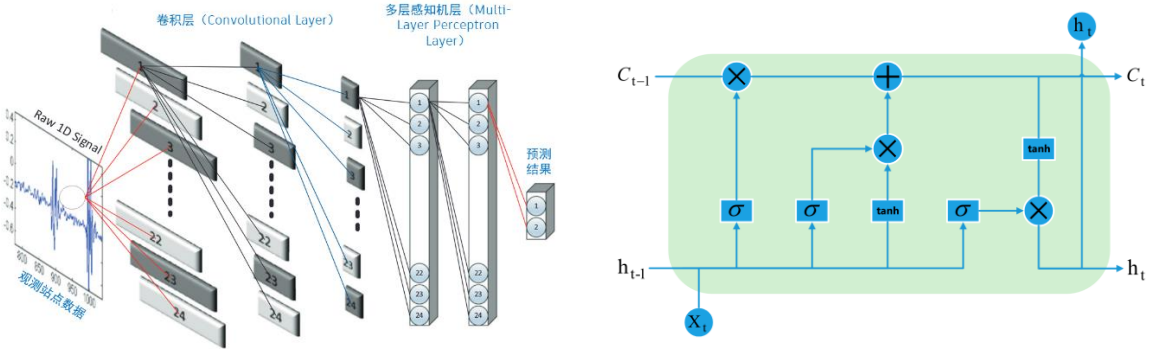
表 1 用于模型训练的观测站点

站点名称	纬度 (°N)	经度 (°E)	海拔 (m)	数据采集开始时间
Fmor	45.02965	5.880547	2140	2013.12
Fcmb	45.017311	6.17845	2460	2015.11
Fber	44.949944	6.237082	2390	2013.12
Fhue	45.10188	6.056158	2064	2013.12
Fgie	45.855289	6.525692	1812	2011.06
Fmon	45.30283	6.56593	2280	2013.12
Fche	45.513248	6.95439	2869	2011.05
Fbon	45.362431	7.05232	2480	2011.05
Fcel	45.49057	6.40921	1924	2011.05
Fsal	44.856754	5.952989	1975	2019.06

（2）1DCNN-LSTM 模型的构建

风吹雪过程在时间上具有连续性，即在一定时间段内，相关监测数据会表现出一定的往复规律。例如，当具体道路沿线首次发生风吹雪时，该地点的监测数据在初始时刻可能显示无风吹雪现象，而在随后的多个时刻中，该地点的监测数据将持续反映出风吹雪现象。这种现象可以在风吹雪过程的时间序列数据中得到体现。基于此，本研究采用 1D CNN 与 LSTM 融合的深度学习模型，结合卷积神经网络（1D CNN）和长短期记忆网络（LSTM）的优势，以更好地捕捉风吹雪事件的时空特征，模型具体构建方法如下：

1D CNN 特征提取：首先将风速、气温、湿度等多通道环境监测数据的时间序列特征整合为一个融合特征矩阵，1D CNN 层负责从输入的时间序列数据中提取局部时空特征。通过在时间轴上滑动的卷积核，1D CNN 能够有效捕捉风吹雪事件在短时间内的变化模式，从而提取出关键的时序特征（图 5a）。这些特征能够反映风吹雪事件在不同时间段的动态变化。通过卷积层的多层堆叠和池化操作，模型能训练学习到不同层级的时序特征，从而提升特征提取的能力。



(a) 1D CNN 结构配置　　(b) LSTM 网络结构及其内存单元

图 5 1DCNN-LSTM 模型结构

LSTM 时序建模：为了进一步捕捉风吹雪事件的长期依赖性，本研究在 1D CNN 层之后引入了 LSTM 层。LSTM 网络擅长处理具有长期依赖性的时间序列数据，可以记忆并理解风吹雪事件在较长时间范围内的趋势和演变。LSTM 的门控机制（图 5b）有助于过滤无关信息和记住关键时

间步的特征，从而使模型能够更好地建模风吹雪事件的时间相关性，提高对风吹雪发生的预测精度。

相比于仅依赖 CNN 的模型，1DCNN-LSTM 模型能够综合考虑短期变化和长期趋势，同时还可以处理不同长度的输入序列，对缺失数据具有更好的适应能力。使得其在实际的风吹雪监测应用中，不仅能够捕捉风吹雪事件的短期变化，还能理解其长期演变趋势，从而提供更加准确和可靠的风吹雪灾害预测。

（3）多变量时间序列预测模型（TFT）的建立

在风吹雪灾害评估中，准确预测环境信息至关重要。尤其是在山区路段，地形因素对风速、气温等的预测准确率有显著影响，使得预测精度往往较低。为了提高现场环境信息预测的精确性，本研究基于加拿大环境与气候变化部（ECCC）的逐时气象站点数据，将建立一个基于多变量时间序列数据的预测模型——Temporal Fusion Transformer (TFT)。TFT 是一种新型的深度学习模型，较为适合处理复杂的多变量时间序列数据。该模型结合了变压器（Transformer）架构的长时依赖建模能力和时间序列数据的时效性特征，能够有效克服传统模型在处理多变量时序数据时的局限性。

TFT 模型的构建与训练涉及多个关键步骤，以有效处理复杂的时间依赖关系，该模型的完整结构如图 6 所示。首先，原始时间序列数据（如风速、气温、湿度等）通过嵌入层转换为高维特征表示，同时通过位置编码层为每个时间步添加位置信息，确保时间序列的顺序信息得以保留。接着，模型利用多头自注意力机制捕捉时间序列中的长时依赖关系和多变量间的交互关系，这使得模型能够关注序列中关键时间步的数据，并提取出有助于预测的特征。门控机制的引入进一步控制信息流动，提高模型对不同时间步信息的选择性和重要性权重，其中包括标准化门和动态卷积门，以有效捕捉时间序列中的动态变化。解码器则将注意力层提取的特征转换为风速预测结果，通过前馈网络和线性变换，将提取的特征映射到实际风速预测值。模型训练过程中，使用历史风速数据和相关气象变量进行训练，选择适当的损失函数（如均方误差）和优化算法（如 Adam），并通过交叉验证调优模型超参数。为了防止过拟合，采用正则化技术，并利用早停策略监控模型在验证集上的表现，以避免过度训练。

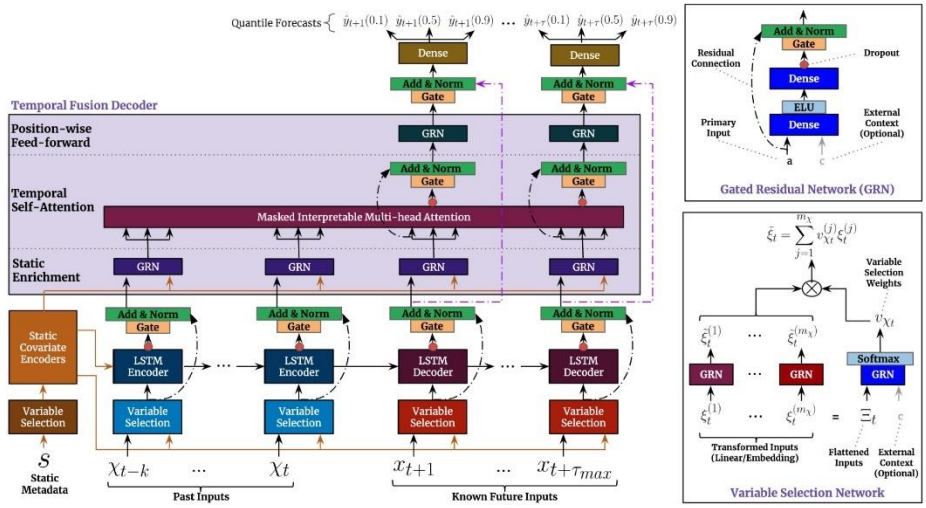


图 6 TFT 模型架构、门控残差网络及变量选择网络

技术路线

本研究技术路线如图 7 所示，研究分为两部分，第一部分基于深度学习模型训练得到风吹雪易发性与现场气象信息预测模型。之后基于 ERA5 长期历史气象数据和现场气象站点实时数据，分别实现长时间大范围的交通线路风吹雪灾害评估，以及中短期、局部路段的交通线路风吹雪灾害预测。两部分结果相互补充，前者提供了全局性的宏观灾害分析，有助于识别易发灾害区域，后者则通过实时数据校正和模型更新，提高预测的时效性和精确度，为具体路段的风雪灾害应急管理提供多尺度数据支持。

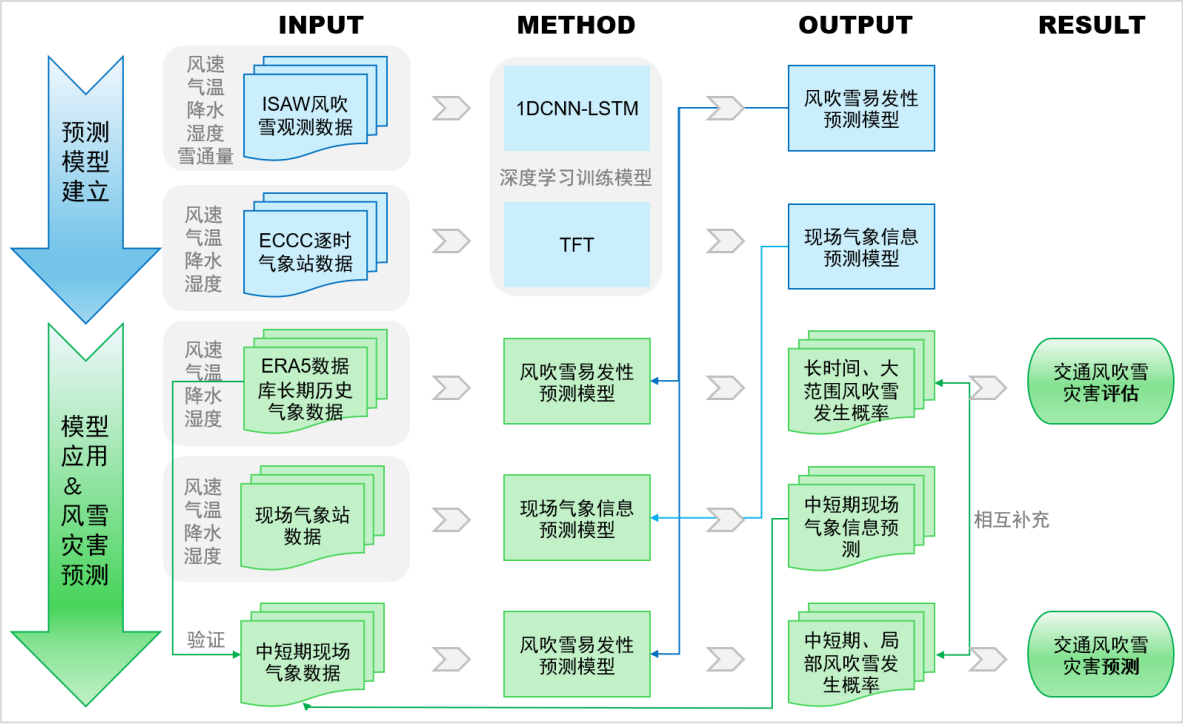


图 7 研究技术路线

试验方案

（1）风吹雪易发性预测模型、现场气象信息预测模型的建立

数据预处理：首先对 ISAW 和 ECCC 的气象数据进行清洗和标准化处理，确保数据的完整性和一致性。ISAW 数据包括风速、气温、湿度、降水量等变量，这些数据经过处理后按时间顺序划分为训练集、验证集和测试集；ECCC 数据则涵盖逐时的风速、气温、湿度等气象信息，经过同样的预处理步骤后划分为训练集、验证集和测试集。

模型训练：针对风吹雪易发性预测，采用 1D CNN 与 LSTM 融合的深度学习模型。1D CNN 层负责提取时间序列数据的局部特征，LSTM 层则捕捉风吹雪过程的长期依赖关系，使用均方误差（MSE）作为损失函数，并通过 Adam 优化算法进行训练。同时，基于 ECCC 数据建立的 TFT 模型，通过嵌入层和位置编码层保留时间序列的顺序信息，结合 Transformer 的长时依赖建模能力，对风速、温度、湿度等气象信息进行精确预测，训练过程同样使用 MSE 作为损失函数，并利用正则化技术和早停策略避免过拟合。

模型评估与测试：使用验证集对 1DCNN-LSTM 和 TFT 模型进行性能评估，分析其预测精度、召回率等指标，并通过不同气象变量组合，测试模型在实际环境中的预测能力，比较其与实际观测数据的差异，为后续优化提供依据。

模型优化：进一步调整模型的超参数设置，优化特征选择和模型结构，结合正则化方法和数据增强技术，提升模型的泛化能力和在不同应用场景中的稳定性。

（2）预测模型部署与应用

将经过优化的风吹雪易发性预测模型和现场气象信息预测模型集成到实际应用系统中，通过实时预测提供风吹雪灾害预警和气象信息预报，助力交通线路的安全管理。在实际应用中，持续收集反馈数据，分析模型在不同环境下的表现，根据反馈信息进一步优化模型参数和结构，确保其在长期运行中的稳定性和精确性。同时，探讨模型在其他气象灾害预测和环境监测中的应用潜力，扩展其在更广泛气象灾害管理中的应用范围。

（3）实际道路沿线气象站的建立及信息采集

为实现对风吹雪灾害的精准监测与预测，本研究将在实际道路沿线建立一系列气象站点（图 8）。这些气象站将按照交通线路的关键节点和易发灾害路段进行布局，确保全面覆盖可能发生风吹雪灾害的区域。每个气象站将配备的多种气象传感器，用于实时监测包括风速、风向、气温、湿度、降水量和积雪深度在内的多项气象参数。

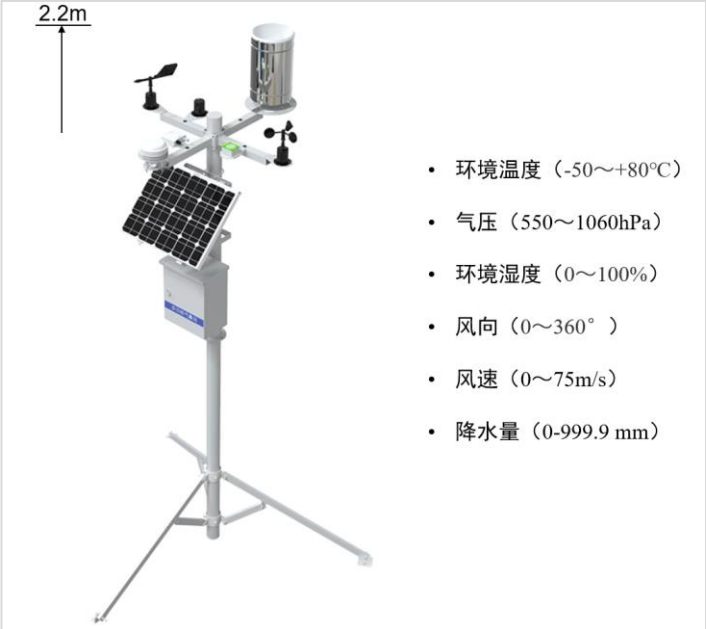


图 8 多要素气象站

在气象站点的设立过程中，将充分考虑地形和环境对数据采集的影响，尤其是在山区路段，气象站的布局和设备的安装将根据当地的地形特征进行优化，以最大限度减少环境因素对数据准确性的干扰。数据采集将以高频率进行，通常每分钟采集一次，并汇总为每小时的平均值。这些数据将通过无线通信系统实时传输至中央控制系统，并与模型中的实时预测数据进行对比分析，以验证模型的预测精度和稳定性。同时，气象站的建设还将考虑到其在极端天气条件下的可靠性和耐久性，确保其在恶劣环境下仍能稳定运行，提供连续的气象数据支持。

可行性分析

（1）开放数据的获取

开放数据的获取为本研究提供了坚实的数据基础。ISAW 风吹雪观测数据（http://www.isaw.ch/）涵盖了阿尔卑斯山脉与比利牛斯山脉道路沿线的详细气象信息。数据来自于约 30 个 ISAW 观测站，其中选取了 10 个站点（见表 1）进行深入分析。其中训练数据站点均具备至少十年的长期观测数据，以减少不确定性并确保数据的可靠性和一致性。数据内容包括平均风速、最大风速、风向、气温、湿度、积雪深度、降水量以及雪通量等关键参数，这些数据不仅覆盖范围广泛，而且具备较高的时效性。每个 ISAW 站点配备了 FlowCapt 声学传感器，这些传感器能够有效记录风吹雪过程中风雪颗粒与传感器碰撞产生的声波，并通过电过滤和频谱分析技术，准确区分风噪声和吹雪信号。

此外，加拿大环境与气候变化部（ECCC）提供的逐时气象站数据，同样为气象信息预测模型的建立研究提供了可靠的基础数据（https://www.canada.ca/en/services/environment/weather.html）。这些数据采集于加拿大中部的萨斯喀彻温省，涵盖了风速、风向、气温、露点温度、相对湿度以及气压等重要气象变量。这些数据详细地按年度季节划分进行分析。为确保数据的有效性和全面性，原始数据被划分为训练集、验证集和测试集，比例为 80%：10%：10%。例如，在春季数据集中，训练集、验证集和测试集分别包括 1736、200 和 200 个观测值。这种数据划分方法使得模型能够得到充分的训练、超参数优化和最终验证，从而提升模型的准确性和可靠性。

（2）现有深度学习框架在模型构建中的应用

深度学习模型的构建得益于现有深度学习框架的成熟性和强大功能。基于 PyTorch、TensorFlow 和 Scikit-learn 等主流框架，本研究能够迅速搭建和训练复杂的模型，例如 1DCNN-LSTM 和 TFT 模型。这些框架不仅支持多种类型的神经网络结构，还提供了丰富的工具库和优化算法，大大简化了模型的开发和调试过程。借助这些框架，使得本研究能够高效地进行模型的构建、迭代和优化，从而确保最终模型在预测精度和性能上的最佳表现。这些工具的先进性和灵活性，使得在处理大规模、多维度的数据时，能够实现更为精准和高效的计算和分析。

（3）所采用方法在气象数据预测方面的广泛应用

本研究所采用的方法在气象数据预测中已被广泛应用，并取得了显著的成效。例如，1DCNN-LSTM 模型在时间序列数据分析中表现优异，已广泛应用于金融、气象和健康监测等领域。同样，TFT 模型因其在处理复杂多变量时间序列数据方面的优势，已在电力负荷预测、销售预测等多个领域展现出良好的适用性。这些成功的先例不仅验证了所选方法的有效性，也为本研究的顺利实施提供了理论支持和实践参考。在表 2 中列举了一些在气象数据预测领域的研究成果，这些研究应用了不同的预测模型，包括时空相关模型、人工智能模型以及混合模型等，在多个地区实现了不同时间尺度的气象信息预测，进一步证明了本研究技术路线和方法的可行性。

表 2 深度学习模型在气象数据时间序列预测方面的应用

预测区域	时间间隔	输入变量	预测方法	相关文献
意大利东利古里亚	3 小时	大气中的物理过程	卡尔曼滤波器	Cassola F & Burlando M, 2012
英国	1 小时	根据大气稳定性类别划分的数据	数值天气预报模型和高斯过程回归（GPR）模型	Hoolohan V & Tomlin AS, 2018

美国德克萨斯州	5 分钟	各个站点的气象因素和历史风速	卷积神经网络和长短期记忆神经网络 (LSTM) 组合	Chen Y et al., 2019
波罗的海地区	10 分钟	历史风速	自回归综合移动平均 (ARIMA)	Yunus K et al., 2016
伊利诺伊州和新泽西州	1 小时	历史风速	Hammerstein 自回归模型	Maatallah OA et al., 2015
北达科他州	1 小时	历史风速	分数-ARIMA	Kavasseri RG & Seetharaman K, 2009
中国蓬莱	10 分钟 和 30 分钟	历史风速	Elman 神经网络	Wang J et al., 2019
Sotavento Galicia	10 分钟 和 1 小时	历史风速	核极限学习机	Fu W et al., 2020
中国青海风电场	30 分钟	历史风速	人工神经网络	Liu H et al., 2013
中国福州和海口	1 天	气象因素和历史风速	门控循环单元 (GRU)	Wu J et al., 2022
美国	10 分钟	气象因素和历史风速	正则化极限学习机	Shang Z et al., 2024
河北风电场和中国内蒙古风电场	1 小时	历史风速	基于变分模态分解、ARIMA 和深度信念网络的自适应混合模型	Zhang J et al., 2020
巴西东北部的北里奥格兰德	10 分钟	历史风速	基于 SSA 和自适应模糊推理系统的自适应混合模型	Moreno SR et al., 2018
中国内蒙古	10 分钟 和 1 小时	历史风速	结合 LSTM、滞后极限学习机、差分进化算法的混合模型	Hu Y & Chen L, 2018
瑞典	10 分钟 和 1 小时	历史风速	基于变分模态分解方法、广义正态分布算法和双向 LSTM 的混合模型	Neshat M et al., 2021
巴西 Parazinho 风电场	10 分钟	历史风速	一种组合堆叠-集成学习和完全集成经验模态分解的分解-集成学习方法	Da Silva RG et al., 2021
中国	15 分钟	气象因素和历史风速	一种使用高速公路门控算法优化局部卷积神经网络配置的混合模型	Dong Y et al., 2021

相关文献：

- Cassola F, Burlando M. Wind speed and wind energy forecast through Kalman filtering of Numerical Weather Prediction model output[J]. Applied energy, 2012, 99: 154-166.
- Hoolohan V, Tomlin A S, Cockerill T. Improved near surface wind speed predictions using Gaussian process regression combined with numerical weather predictions and observed meteorological data[J]. Renewable Energy, 2018, 126: 1043-1054.

- Chen Y, Zhang S, Zhang W, et al. Multifactor spatio-temporal correlation model based on a combination of convolutional neural network and long short-term memory neural network for wind speed forecasting[J]. Energy Conversion and Management, 2019, 185: 783-799.
- Yunus K, Thiringer T, Chen P. ARIMA-based frequency-decomposed modeling of wind speed time series[J]. IEEE Transactions on Power Systems, 2015, 31(4): 2546-2556.
- Maatallah O A, Achuthan A, Janoyan K, et al. Recursive wind speed forecasting based on Hammerstein Auto-Regressive model[J]. Applied Energy, 2015, 145: 191-197.
- Kavasseri R G, Seetharaman K. Day-ahead wind speed forecasting using f-ARIMA models[J]. Renewable energy, 2009, 34(5): 1388-1393.
- Wang J, Wang S, Yang W. A novel non-linear combination system for short-term wind speed forecast[J]. Renewable Energy, 2019, 143: 1172-1192.
- Fu W, Wang K, Tan J, et al. A composite framework coupling multiple feature selection, compound prediction models and novel hybrid swarm optimizer-based synchronization optimization strategy for multi-step ahead short-term wind speed forecasting[J]. Energy Conversion and Management, 2020, 205: 112461.
- Liu H, Tian H, Pan D, et al. Forecasting models for wind speed using wavelet, wavelet packet, time series and Artificial Neural Networks[J]. Applied Energy, 2013, 107: 191-208.
- Wu J, Li N, Zhao Y, et al. Usage of correlation analysis and hypothesis test in optimizing the gated recurrent unit network for wind speed forecasting[J]. Energy, 2022, 242: 122960.
- Shang Z, He Z, Chen Y, et al. Short-term wind speed forecasting system based on multivariate time series and multi-objective optimization[J]. Energy, 2022, 238: 122024.
- Zhang J, Wei Y, Tan Z. An adaptive hybrid model for short term wind speed forecasting[J]. Energy, 2020, 190: 115615.
- Moreno S R, dos Santos Coelho L. Wind speed forecasting approach based on singular spectrum analysis and adaptive neuro fuzzy inference system[J]. Renewable energy, 2018, 126: 736-754.
- Hu Y L, Chen L. A nonlinear hybrid wind speed forecasting model using LSTM network, hysteretic ELM and Differential Evolution algorithm[J]. Energy conversion and management, 2018, 173: 123-142.
- Neshat M, Nezhad M M, Abbasnejad E, et al. A deep learning-based evolutionary model for short-term wind speed forecasting: A case study of the Lillgrund offshore wind farm[J]. Energy conversion and management, 2021, 236: 114002.
- da Silva R G, Ribeiro M H D M, Moreno S R, et al. A novel decomposition-ensemble learning framework for multi-step ahead wind energy forecasting[J]. Energy, 2021, 216: 119174.
- Dong Y, Wang J, Xiao L, et al. Short-term wind speed time series forecasting based on a hybrid method with multiple objective optimization for non-convex target[J]. Energy, 2021, 215: 119180.

四、研究工作的总体安排及进度

研究工作总体安排及进度如图 9 所示：



图 9 研究工作进度安排

五、研究工作的预期成果及成果提交形式

通过按计划完成项目的研究内容，预期获得如下成果：

- 理论成果：环境条件和积雪特性对起动风速的影响规律；
- 技术方法：风吹雪灾害易发性判断模型和现场气象时间序列预测模型；
- 发表论文：预计发表 2 篇 EI 及以上检索文章；
- 学术交流：参加 1 次国际风雪学术会议；
- 知识产权：发明道路风吹雪灾害评估预测专利 1 项

六、研究工作条件和基础（包裹过去的研究工作基础，现有的主要仪器设备、研究技术及协作条件等）

过去的研究工作基础

针对交通道路风吹雪灾害，申请者所在课题组积累了大量的风洞试验和 CFD 模拟基础。在风洞试验方面，团队在石家庄铁道大学风工程研究中心的风洞中，采用木屑、盐、二氧化硅、苏打等近十种雪颗粒替代物，成功模拟了风致雪漂移现象，获得了丰富的试验经验。在交通线路的风致雪堆积模拟中，团队应用了侵蚀沉积、混合模型等多种方法，分别进行了稳态与瞬态的模拟，并掌握了运用 Fluent 进行风吹雪模拟的关键技术。**以此为基础，申请者在攻读硕士学位期间，直接参与了交通线路风吹雪灾害的模拟工作（2020-2023 年），利用上述方法对路堑风吹雪灾害演化过程进行了深入研究，并成功模拟了不同断面形式路堑的风吹雪灾害。**相关成果对于理解路堑风吹雪灾害的形成机理、分析其时空分布特征，以及提出预测和防治措施等方面具有重要的现实意义。

此外，申请者在攻读博士学位期间（2023 年 9 月起），在风吹雪灾害起动风速的研究方面进

行了积极的探索。**在课题组支持下，申请者及团队成员分别于 2023 年 12 月和 2024 年 3 月，青藏高原东南部山区的主要国道沿线进行了详细的现场实测（图 10）**。利用便携式风洞，对不同雪样的起动风速进行测量。通过分析所采集的不同类型雪样的温湿度、堆积密度、休止角等数据，探讨了上述因素对风吹雪发生条件的影响，建立了多层次的风雪易发性评估模型。研究结果不仅丰富了该地区的实测数据，还能够具体量化风吹雪现象的发生概率和影响范围，并且提供更加适用于实测地区特征的风吹雪预测和评估工具。



(a) 雪样信息测量，西藏昌都



(b) 现场风速采集，四川理塘

图 10　青藏高原东南部山区风雪特性测量

现有仪器设备

为研究风吹雪物理特性，申请者团队已经进行了充分的前期准备，制作了多台适用于现场的设备和装置（如图 11 所示），可有效解决现场测试中的挑战。具体来说而言，使用 THM-01 工业温湿度仪记录现场的温湿度变化，数据采集频率为 0.5Hz，温度测量分辨率为 0.1℃，湿度测量分辨率为 0.1%RH。利用自制雪通量仪和风速轮廓线测量仪，测量近地面处风雪分布情况。在判别风吹雪现象的易发性时，起动风速尤为关键。为此，团队在现场测试中使用了自制的便携式风洞进行测量。该风洞截面为边长 0.4m 的方形，动力段和试验段总长为 2.1m，动力由 EG-4A-2 轴流式风机提供，风机风量为 11053m^3/h。为确保风洞内气流的均匀性，通过距离风机 20cm 处的蜂窝器对气流进行整流，将气流横向不均匀度控制在 5%以内。



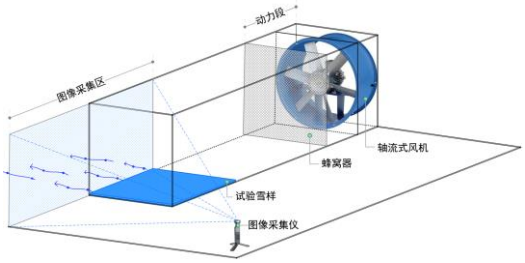
(a) THM-01 工业温湿度仪



(b) 雪通量测量仪



(c) 风速轮廓线测量仪



(d) 雪样起动风速测量仪

图 11　现有仪器设备

此外，为满足深度学习等研究任务对算力的巨大需求，申请者团队自 2023 年起建立了独立的计算集群，为深度学习模型的训练与优化提供了强大的硬件支持。该集群配备了 1456 个公共核心，总核心数达 1814 个，提供了强大的并行计算能力，能够高效处理复杂的深度学习任务。团队拥有 6032GB 的运行内存，确保了大规模数据处理的顺畅和稳定运行。同时，160TB 的公共存储池为存储和管理海量实验数据及模型文件提供了充裕的空间。网络带宽高达 10Gbps，支持高速数据传输和远程协作。

研究技术

本研究的技术方法结合了深度学习技术和现场实测数据，旨在提升风吹雪灾害预测的精度和鲁棒性。具体而言，本研究采用了 1D CNN-LSTM 和 TFT 模型，通过深度学习技术捕捉风吹雪事件的时空特征。同时结合现场实测数据，为模型提供精确的环境条件输入，确保模型的实际应用价值。

（1）深度学习模型

深度学习模型在时间序列数据处理和预测中展现了强大的能力，本研究具体采用了以下两种模型，分别用于捕捉风吹雪事件的短期和长期特征：

1D CNN-LSTM 模型：该模型结合了卷积神经网络（CNN）和长短期记忆网络（LSTM）的优势。1D CNN 层用于提取输入数据中的局部时空特征，特别是风速、气温、湿度等环境变量在短时间内的动态变化。随后，通过 LSTM 层建模这些特征之间的时间依赖性，捕捉风吹雪事件的长期趋势。1D CNN-LSTM 模型能够有效应对风吹雪灾害预测中的复杂时空模式，提高对灾害发生时机的预测精度。

Temporal Fusion Transformers（TFT）模型：该模型具备强大的特征选择和关系建模能力，尤其适用于多变量的时间序列数据预测。在风吹雪灾害的预测中，TFT 模型通过多层注意力机制，不仅能够捕捉风吹雪事件关键气象要素的动态变化，还能够根据实时数据更新预测结果，提高模型的响应速度和适应能力。

（2）现场气象信息实测

风吹雪灾害具有显著的地域性差异，环境变量的变化直接影响到风吹雪事件的发生与演变。因此，现场实测数据对模型的输入和验证至关重要。本研究中的通过建立多个高海拔地区的观测站，这些站点配备了多要素气象传感器，能够实时监测风吹雪通量、风速、气温、相对湿度等关键气象变量。通过对这些实测数据的充分利用，本研究在模型训练和测试中能够确保预测结果与实际情况的高度一致性。

协作条件

申请者团队在风吹雪灾害研究领域具有强大的协作能力和资源优势。自 2014 年起，团队每年冬季深入新疆开展风吹雪灾害调研，积累了宝贵的现场测试经验。通过参研克塔铁路风吹雪研究项目，团队还获取了该地区气象站、雪通量和雪深监测设备所提供的珍贵数据，为开展系统的现场测试提供了重要的资源支持，这些合作关系和实地经验为本研究的深入推进创造了有利条件。并且这一过程中，申请者研究团队与当地政府、交通管理部门以及气象单位建立了密切合作，为研究的顺利开展奠定了坚实的基础。